Airbyte y PostgreSQL para ETL con CDC

Contenido

OBJE	ETIVO DEL LABORATORIO	2
•	Objetivos específicos	2
DIAG	GRAMA LÓGICO	2
САРТ	TURAS DEL PROCESO DE CONFIGURACIÓN	3
•	Clonación del repositorio airbyte	3
•	Creación de contenedores Docker	4
•	Comprobación de contenedores	4
•	Inicio de sesión en Airbyte UI	5
•	Definición de Fuente de datos para Airbyte	6
•	Definición de destino en Airbyte	8
•	Definición de conexión en Airbyte	8
САРТ	TURAS DE OPERACIONES DML Y SINCRONIZACIÓN AIRBYTE	10
•	INSERT	10
•	UPDATE	11
•	DELETE	12
•	JOB HISTORY	13
REPO	OSITORIO	13

OBJETIVO

Implementar una solución de Change Data Capture (CDC) utilizando Airbyte y PostgreSQL, permitiendo la extracción y sincronización de datos modificados en tiempo real.

- Objetivos específicos
- Desplegar un entorno funcional de Airbyte utilizando Docker.
- Configurar una base de datos PostgreSQL preparada para CDC.
- Establecer una conexión en Airbyte que refleje los cambios en las tablas de la base de datos a través de sincronizaciones periódicas.

DIAGRAMA LÓGICO

1. <u>Capa de Ingesta de Datos</u>

 Airbyte: Plataforma de integración de datos que se conectará a PostgreSQL para capturar los cambios de datos.

2. Capa de Procesamiento de Streaming

• **Debezium**: Utilizado para la captura de cambios en PostgreSQL y transmitirlos a Airbyte.

3. Capa de Base de Datos y Almacenamiento

• PostgreSQL: Base de datos que almacena los datos de empleados y está configurada para CDC.

4. Capa de Visualización

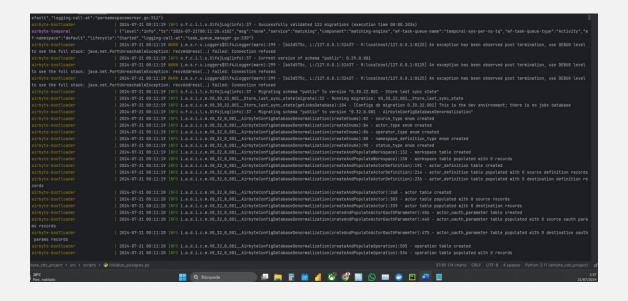
 Airbyte UI: Interfaz gráfica utilizada para configurar y monitorizar las conexiones y sincronizaciones.

CAPTURAS DEL PROCESO DE CONFIGURACIÓN

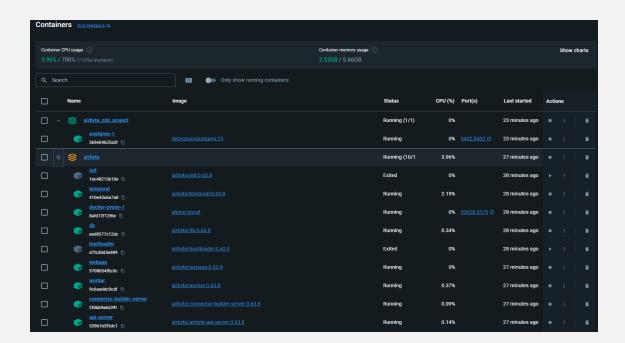
• Clonación del repositorio airbyte

git clone --depth=1 https://github.com/airbytehq/airbyte.git cd airbyte

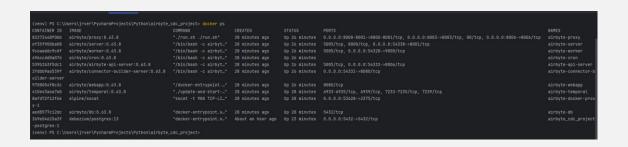
./run-ab-platform.sh



• Creación de contenedores Docker



• Comprobación de contenedores

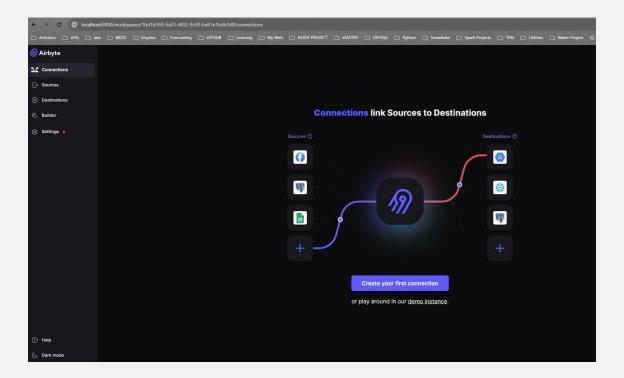


4

Inicio de sesión en Airbyte UI

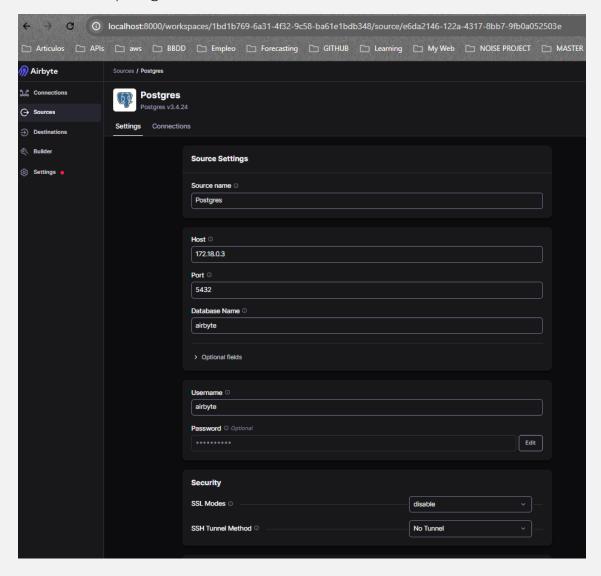
Usuario: airbyte

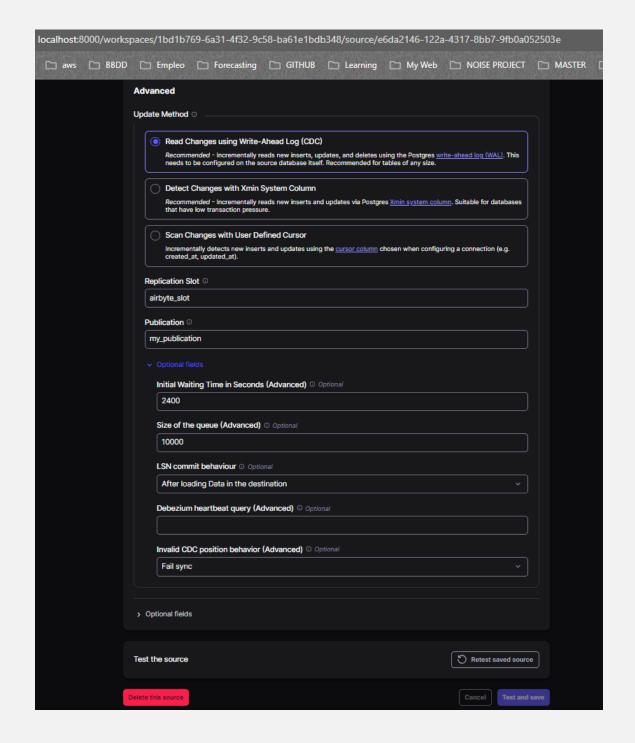
Contraseña: password



• <u>Definición de Fuente de datos para Airbyte</u>

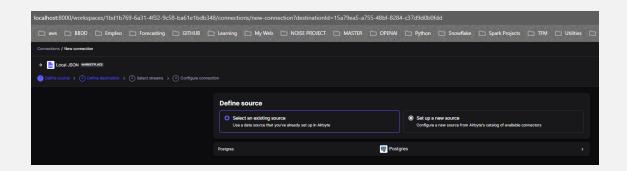
El host para ser reconocido correctamente tuve que indicar la ip del contenedor postgres en Docker.



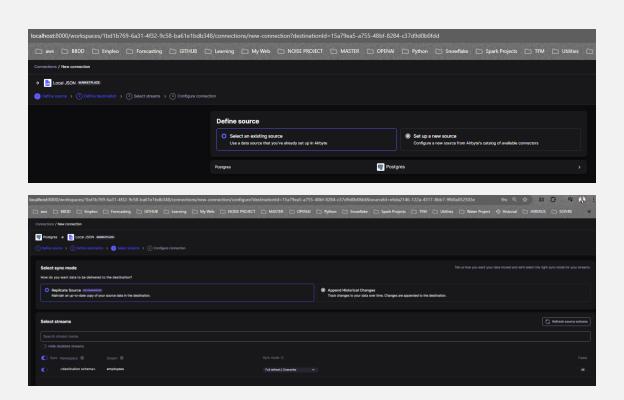


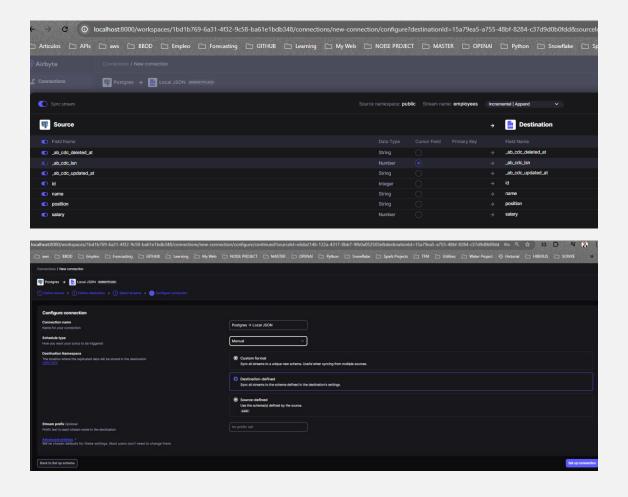
• Definición de destino en Airbyte

Se define un destino Local Json para el directorio local/airbyte_output



• Definición de conexión en Airbyte





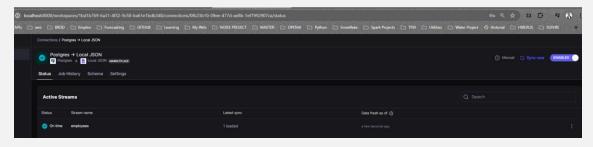
CAPTURAS DE OPERACIONES DML Y SINCRONIZACIÓN AIRBYTE

• INSERT

En primer lugar, se muestra el acceso al contenedor postgres en dokcer y consulta la tabla existente sin registros.

Posteriormente se ejecuta sql para insert y se muestra tabla actualizada.

Manualmente se lanza una sincronización con resultado exitoso desde el UI de Airbyte



A continuación, se accede al contenedor airbyte-server en Docker para recuperar y mostrar el archivo json donde persiste la información de los cambios en postgres capturada por airbyte.

```
(venv) PS C:\Users\jrver\PycharmProjects\Python\ainbyte_cdo_project> docker exec :: alrbyte-server /bin/bash
(alrbytegef3599008080 appjs_cd /tmp/airbyte_local/airbyte_output
(alrbytegef3599008080 airbyte_coutput) is
alrbyte_ram_employees_ison\
[alrbyte_ram_employees_ison\
[alrbyte_ram_employees_ison\
[f_sirbyte_ram_employees_ison\
[f_sirby
```

Se ejecuta un insert adicional:

```
Instale la versión más reciente de PowerShell para obtener nuevas características y mejoras. <a href="https://aka.ms/PSWindows">https://aka.ms/PSWindows</a>

(venv) PS C:\Users\jrver\PycharmProjects\Python\airbyte_cdc_project> docker exec -it 369e04625a3f /bin/bash root@369e04625a3f:/# psql -U airbyte -d airbyte psql (13.15 (Debian 13.15-1.pgdg110+1))

Type "help" for help.

airbyte=# INSERT INTO employees (name, position, salary) VALUES ('Jane Smith', 'Data Scientist', 80000);

INSERT 0 1 airbyte=# |
```

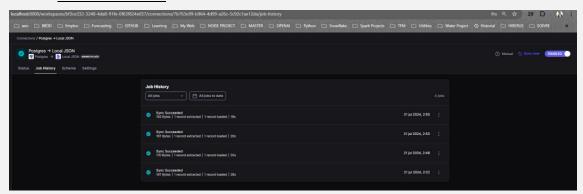
Y se recupera el json actualizado:

UPDATE

DELETE

```
(venv) PS C:\Users\jrver\PycharmProjects\Python\airbyte_cdc_project> docker exec -it 369e04625a3f /bin/bash
root@369e04625a3f:/# psql -U airbyte -d airbyte
psql (13.15 (Debian 13.15-1.pgdg110+1))
Type "help" for help.
airbyte=# INSERT INTO employees (name, position, salary) VALUES ('Jane Smith', 'Data Scientist', 80000);
airbyte=# SELECT * FROM employees;
1 | John Doe | Developer | 75000
 2 | Jane Smith | Data Scientist | 80000
(2 rows)
airbyte=# UPDATE employees SET position = 'Data Engineer' WHERE name = 'John Doe';
UPDATE 1
airbyte=# SELECT * FROM employees;
 2 | Jane Smith | Data Scientist | 80000
 1 | John Doe | Data Engineer | 75000
(2 rows)
airbyte=# DELETE FROM employees WHERE name = 'Jane Smith';
DELETE 1
airbyte=# SELECT * FROM employees:
 1 | John Doe | Data Engineer | 75000
```

• JOB HISTORY



REPOSITORIO

https://github.com/Rafavermar/airbyte_cdc_etl_project